2025-2026-2《Python 程序设计》大作业

办公室复印纸采购优化师——“谁是金牌采购官”?

在当今数字化转型的浪潮中，数据驱动决策已成为企业提升运营效率的核心竞争力。本课程旨在通过一个高度模拟现实商业场景的综合性项目——“办公室耗材采购优化”，引导同学们系统性地掌握 Python 在全栈数据处理领域的核心应用。

课题背景与要求

【背景描述】

课题设定在一个虚拟的学校行政管理场景中。你被任命为学校后勤办公室的首席数据采购官，肩负着一项关键任务：在每年预算有限的前提下，确保学校 A4 复印纸的充足供应。

市场环境瞬息万变，电商价格波动频繁，如何利用技术手段监控市场、分析走势并建立科学的采购模型，成为衡量同学们能力的标准。

【课题目标】

某学校办公室拟购入复印纸若干包/箱，来满足本年 5 月 1 日到明年 4 月 30 日使用。目标是规划复印纸购买策略，实现在满足指定约束前提下，全年总购买数量(箱)达到最多。需开展数据的采集、清晰、分析以及预测决策等工作。

【课题设置】

为激发学生的学习热情，提升团队协作能力，并检验阶段性学习成果，课题整体采用三阶段 PK 机制：

阶段 1: 爬虫技能 PK。共计 20 分,分基础得分和限时 PK 得分，各 10 分；

阶段 2: 分析与可视化技能 PK。共计 20 分,分基础得分和限时 PK 得分，各 10 分；

阶段 3: 预测决策技能 PK。共计 30 分，分基础得分 10 分，约束合规性得分 10 分，最优采购 PK 得分 10 分（全年级排名赋分）。

- **基础得分**：根据每个同学提交的分析报告、代码、数据等材料，按照评分标准由 AI 大模型进行评分，每个阶段各 10 分。
- **PK 得分**：根据各阶段的评分标准评分。其中阶段 3 的 PK 得分将进行全年级排名赋分，阶段 1 和阶段 2 总分排名前 20%的同学将接受其他同学挑战，在阶段 3 中（1 对多的挑战中），被挑战者若胜利，保留原成绩；若败北，将拿出 5 分赠与挑战胜利者（均分给挑战胜利者，向上取整）。
  - **挑战报名规则**：登记时采用微信投票方式，每人只能挑战 1 人，被挑战者最多被 5 人挑战。

- ✓ 挑战者（最多 5 人）的挑选方式以排名从后向前选择 5 人（所以请谨慎挑选挑战对手，以避免因为挑战者排名在其他挑战者之前导致的挑战无效。）
- ✓ 排名前 20%的同学也可以向排名靠前的同学进行挑战，但不接受向排名靠后的同学的挑战。

【课题要求】

课题核心考查 Python 的基础、爬虫实践、数据分析以及算法策略等能力，要求学生掌握：

(1) 数据获取与处理：熟练运用 Requests 库与 BeautifulSoup/Selenium 框架进行电商数据爬取，并处理反爬机制。

(2) 数据分析与清洗：掌握 Pandas 与 NumPy 库，进行数据清洗、转换及基础统计分析。

(3) 数据可视化：利用 Matplotlib 与 Seaborn 库,将复杂数据转化为直观的图表,辅助决策。

(4) 科学建模与优化：构建时间序列预测模型与简单的线性规划模型，实现采购策略的最优化

第一阶段：数据猎手——爬虫与基础分析

【任务简介】

要求从电商平台爬取尽可能多的多款 A4 复印纸的历史价格数据，分析其价格在一年内（初始时间为去年 4 月 1 日开始）的波动规律及促销策略等，为后续数据分析与预测、采购策略实施等提供数据基础。

【赛制安排】

该任务开展周期为第 7 周～第 9 周，时间安排如下：

(1) 第 7 周，爬虫技术分析（上课）

(2) 第 8 周，爬虫案例分享（同学讲解其程序）

(3) 第 9 周，PK 赛

整体分为基础能力实践、限时 PK 赛两个部分。

【基础能力实践的任务要求】

(1) 选择 1-2 个主流电商平台（如京东、淘宝、拼多多、慢慢买等）爬取指定商品的历史价格数据，可以包括但不限于以下字段：商品名称、规格、价格、价格变动时间、促销活动标签（如“满减”、“折扣”）、评论数、销量等

(2) 将爬取数据保存为 CSV 文件

(3) 基本数据清洗与统计分析处理，并保存处理后数据及结果数据文件：对爬取的原始数据进行清洗，如处理缺失值、异常值(如价格突变为 0)，统一数据格式（如时间戳转换）；开

展可能的统计分析，如价格分布分析(均值、中位数、标准差)、时间趋势分析（如价格周期性波动、促销活动对价格的影响）、关联分析(如销量与价格的关系、评论数与评分的相关性)

(4) **提交材料要求**：

① 一个功能完善的 Python 爬虫脚本，命名格式为“学号_spider.py”：能够自动抓取指定电商平台（或模拟环境）的 A4 纸价格信息

② 一个功能完善的 Python 预处理脚本，命名格式为“学号_preprocess.py”：能够自动识别并处理爬取数据的缺失值、异常值、重复数据、格式等问题，并能对处理过的数据进行简单分析

③ 一份《A4 纸爬虫技术报告》，命名格式为“学号_姓名_爬虫报告.docx”，内容涵盖课题内容及目标、爬虫方案、原始数据情况、基本清洗处理方案、清洗后数据展示等，初步洞察市场情况。

④ 该任务开展周期为第 7～9 周,**截止 2026 年 4 月 30 日 23:59 分**,提交材料至学习通

【限时 PK 赛的任务说明】:

(1) 赛题任务由教师课堂发布：爬取指定的商品在若干个日期下的价格数据（如给定商品 ID、品牌、日期、型号、商品来源网站、商品来源店铺），学生在有限时间内，完成指定商品价格的爬取，将数据处理后存入文件。

(2) **限时 2 小时**：学生在本地或机房修改代码，实现指定数据爬取

(3) **提交内容**：学生仅需提交“学号_result.csv”(抓取结果)和“学号_spiderPK.py”(爬虫代码)

(4) **要求数据文件的内容格式为**：商品 ID、日期、真实平台价格、品牌、型号、商品来源网站、商品来源店铺、数据获取时间

【知识点及技术建议】

1. Python 基础：巩固列表、字典、函数及文件操作（CSV/Excel 读写）等基础知识。
2. 网页结构解析：理解 HTML/CSS 基础，DOM 树结构以及 F12 开发者工具的使用。
3. 静态/动态爬虫实战：
   - 使用 Requests 库发送 HTTP 请求，处理响应状态码。
   - 运用 BeautifulSoup 或 lxml 解析网页标签，精准提取商品名称、单价、店铺名、销量等关键信息。
   - 应对简单的反爬策略，如 User-Agent 伪装、请求频率控制等。
4. 数据清洗与存储：
   - 去除无效数据（如“价格面议”、“缺货”等条目）。
   - 统一数据格式（将“¥99.0”转换为浮点数 99.0）。

5. 基础统计分析：

- 计算不同品牌(如得力、晨光)的平均价格、最高/最低价及价格波动范围等
- 分析价格与销量的相关性，识别市场中的“高性价比”产品。

【评分标准】

该阶段共计 20 分：

(1) 基础能力分（共 10 分）：

① 报告内容与格式（2 分）：内容结构是否完整规范；文字表达是否清晰专业

② 爬虫方案设计与实现（4 分）：是否明确数据来源（如京东、淘宝、拼多多、慢慢买等平台）、是否考虑反爬策略（如请求头设置、代理 IP、请求频率控制等）；爬虫代码是否完整、可运行；数据是否获取、使用是否合规（如是否遵守 robots.txt 协议，是否避免高频请求，是否注明数据用途为学习研究）

③ 数据清洗与预处理方案与实现（4 分）：是否识别并处理缺失值、异常值、重复数据、格式不一致等问题；预处理代码是否完整、可运行；是否进行必要的数据转换（如价格单位统一、时间格式标准化、分类变量编码等），为后续分析打好基础

(2) PK 得分（共 10 分）

① 价格数据的准确率和覆盖率：由教师端裁判程序自动判分（8 分）

② 代码质量，是否完整、可运行、可得到结果 csv 文件数据（2 分）

说明：若参与第 8 周程序分享，整体分数上浮 2 分，但总分不超过 20 分

第二阶段：数据参谋——可视化与科学建模

【任务简介】

根据阶段 1 处理得到的数据，进行进一步分析，展示可视化分析结果，并建立价格模型，用于预测特定月份的商品价格。

【赛制安排】

该任务开展周期为第 10 周～第 12 周，时间安排如下：

(1) 第 10 周，可视化和分析技术（上课）

(2) 第 11 周，案例分享（同学讲解其程序）

(3) 第 12 周，PK 赛

整体分为基础能力实践、限时 PK 赛两个部分。

【基础能力实践的任务要求】

(1) 通过图表直观展示分析结果，增强数据可读性，如：

① 趋势可视化：绘制历史价格折线图，观察整体是呈上升、下降还是平稳趋势。

② 季节性分析：分析复印纸价格是否存在周期性波动。

- **提示：**结合复印纸市场特性，例如开学季（2 月/9 月）或年底办公采购高峰是否会导致需求增加从而影响价格?

③ 相关性分析：如果数据集中包含“销量”或“原材料价格”等其他特征，分析它们与复印纸价格的相关性

④ 建议多样化图表展示，如：

- 折线图：展示商品价格随时间的变化趋势。
- 柱状图/箱线图：对比不同商品的促销活动效果或价格分布。
- 散点图：分析价格与销量、评论数的相关性。
- 词云图：展示商品评论中的高频关键词（可选）。
- 交互性：使用 Plotly 或 Dash 实现动态交互图表等

(2) 构建一个 Python 预测模块，能够分析历史数据特征，预测该品牌复印纸未来一个月（30 天）的价格走势，并输出可视化的趋势图

① 默认已经通过阶段 1 爬虫获取了某品牌或多种品牌复印纸的历史销售数据（包含时间、价格、规格、销量等）

② 需至少选择并实现一种预测模型，鼓励尝试多种模型并对比

- 基准模型：使用简单的统计方法作为基准，例如移动平均线或历史均值等
- 其他模型：
  - 使用 statsmodels 库实现 ARIMA 或 SARIMA 模型(捕捉线性趋势和季节性)
  - 使用 scikit-learn 实现线性回归或随机森林回归（需构造滞后特征）
  - 使用 TensorFlow 或 PyTorch 构建 LSTM 长短期记忆网络，捕捉长期依赖关系
  - 使用 Facebook 开源的 Prophet 库，处理具有强烈季节性和节假日效应的商业数据

(3) 模型评估与优化：不能只看预测结果，必须有量化指标证明模型的准确性

① 训练集划分：训练集（如前 80%）和测试集（后 20%），严禁打乱时间顺序

② 评估指标：均方根误差(RMSE)和平均绝对误差(MAE)，数值越小模型越精准

③ 可视化结果：绘制“测试集真实价格”与“模型预测价格”曲线，直观展示拟合效果

(4) **提交材料要求**：

① 一个功能完善的 Python 分析预测脚本，包括两部分功能：

- 可视化分析处理部分，命名为“学号_visual.py”，
- 模型预测部分，命名为“学号_model.py”，实现如输入预算金额及需求参数，

输出建议购买的品牌、数量及预计花费。

② 一份详尽的《A4 纸年度价格趋势分析报告》，命名为“学号_姓名_分析报告.docx”，内容需包含数据可视化图表展示与分析（如价格趋势、品牌对比、影响价格因素等）、模型假设、参数设定、策略建议及风险评估等内容。

(5) 该任务开展周期为第 10～13 周,截止 2026 年 5 月 30 日 23:59 分,提交材料至学习通。

【限时 PK 赛的任务说明】:

(1) 赛题任务由教师课堂发布：教师整合包括 10 种不同品牌型号的复印纸在过去 12 个月内的标准化数据集，包含字段：商品 ID、日期、品牌、型号、价格。学生基于该统一数据，完成对指定商品在未来某个时间区间内的价格预测

(2) 限时 2 小时：学生基于该未知的不同品牌和型号复印纸的历史数据，构建预测模型

(3) **提交内容**：仅需提交“学号_predict.csv”（预测结果）和“学号_predict.py”（预测代码）

(4) **要求数据文件的内容格式为**：商品 ID、日期、预测价格、价格趋势（+涨/-跌）、品牌、型号、数据获取时间

【知识点及技术建议】

1. 数据可视化：使用 Matplotlib 和 Seaborn 绘制
   (1) 动态折线图，展示价格变化趋势。
   (2) 绘制柱状图，直观对比不同品牌的价格差异。
   (3) 利用散点图分析价格与销量的分布关系，识别异常值。
2. 科学计算与建模：运用 NumPy 进行高效的数组运算，处理大规模数据。
3. 时间序列分析：采用移动平均法或简单的线性回归（借助 Scikit-learn 或 Statsmodels 库），预测下个月的纸张价格走势。
4. 优化模型构建：如建立线性规划模型；设定目标函数（最大化总纸张数量）与约束条件（总成本不超过预算、库存满足需求等）。
5. 策略制定与优化：
   (1) 基于模型预测结果，制定“囤货策略”或“按需购买策略”。
   (2) 分析模型的敏感性，评估预算波动对采购决策的影响。

【评分标准】

该阶段共计 20 分，重点考察学生对数据的深度分析能力、可视化呈现效果，以及采购策略模型的科学性与实用性：

(1) 基础能力分（共 10 分）：

① 报告内容与格式（2 分）：内容结构是否完整规范；文字表达是否清晰专业

② 可视化数据分析（4 分）：图表是否使用规范，类型是否恰当；图表元素是否齐全、视觉效果与信息表达是否专业清晰；影响因素及相关性分析等讨论是否到位

③ 价格预测模型构建（4 分）：模型选择是否合理、代码是否正确、是否合理划分训练集与测试集开展模型训练与测试、预测结果分析讨论是否到位

(2) PK 得分（共 10 分）：

① 预测数据的均方根误差和趋势准确率：由教师端裁判程序自动判分（8 分）

② 代码质量，是否完整、可运行、可得到结果 csv 文件数据（2 分）

说明：若参与第 11 周程序分享，整体分数上浮 2 分，但总分不超过 20 分

第三阶段：模拟实战 PK

【任务简介】

根据阶段 1 和 2 爬取处理得到的数据、训练得到的策略模型，开展复印纸购买策略实践，即如何规划复印纸购买策略，可以满足使用需求，且购买尽可能多的复印纸。购买的复印纸不限品牌，不限购买平台。

评测基本步骤要求：

(1) 首先：在建好模型后，运行模型，模型需给出第一次输出，其内容应包括 5 月 1 日和当天剩余的 20 箱纸（虽然初始值为 40 箱，但是 5 月 1 日当天要扣除 5 月要消耗的 20 箱纸，因此这里输出应该是 20 箱纸）。

(2) 之后，老师将以问卷调查的方式，给出 10-14 次输入信息：

① 问卷调查每一次给出的输入信息包括：时间（月+日）、品牌、型号、价格。

- 程序根据问卷要求，获取输入格式为：month.day, price, brand

② 学生依次将格式化信息录入到程序中，程序根据每一次的输入信息，即时给出决策输出，包括购买时间（月+日），购买单价，购买数量（单位为箱，若不购买，数量为 0），购买后存货数量，剩余预算。

- 程序数据格式：month.day, price, PurchaseNum, StorageNum, BudgeLeft

③ 学生在问卷中填写程序给出的决策结果

④ 问卷调查的数据，要求顺序录入，禁止在回答过程中翻回前面的问题重新填写

【任务具体要求】

目标是拟购入 70g 复印纸若干箱，每箱 5 包，每包 500 张，来满足本年度 5 月 1 日到下一年度 4 月 30 日使用。

基础参数设定及条件约束：

- 初始时间为本年度 4 月 30 日，初始库存为 40 箱
- 设定办公室储存空间最多放置 150 箱复印纸（不得超出）
- 预算为 20000 元，用于本年度 5 月 1 日到下一年度 4 月 30 日共 12 个月的采购，不得超额，约定：
  - 每年 3，4，5，6，9，10，11，12 月使用 20 箱纸
  - 1，2，7，8 月使用 10 箱纸
  - 每月的 1 号，进行存货检查，确保有相应存货以供该月使用，此时需要直接核减该月消耗量，即在核减该月消耗量后，库存数量必须≥0。核减的复印纸不会放置在办公室
  - 最后，下一年度 4 月 30 日，必须确保有 20 箱纸的存货以供下一年度 5 月使用。
  - 每次购买后，计算的存货数量为购买数量+原存货数量（已扣除当月预计消耗）

该任务开展周期为第 13 周～第 16 周，时间安排如下：

(1) **第 13 周**，决策模型设计

(2) **第 14 周**，PK 赛测试（模拟测试，验证数据格式）

(3) **第 15 周**，案例分享（同学讲解其程序）

(4) **第 16 周**，PK 赛决赛

【材料提交要求】

(1) 一份《采购决策模型报告》，命名格式为“学号_姓名_决策报告.docx”，内容包括复印纸价格影响因素调研、购买策略模型的建模与分析等方面的介绍，要求内容真实、完整，逻辑清晰，格式规范

(2) 一个功能完善的 Python 决策代码文件，命名为“学号_decision.py”,能够根据采购场景的设定和每次输入，得到需要的输出结果

(3) 该任务开展周期为第 10～16 周,**截止 2026 年 6 月 16 日 23:59 分**,提交材料至学习通。

【评分标准】

该阶段共计 30 分，评分如下：

(1) **报告（10 分）**：旨在考察学生从数据洞察到策略构建的综合能力

① 报告内容与格式（2 分）：内容结构是否完整规范；文字表达是否清晰专业

② 价格影响因素分析（4 分）：是否涵盖了关键的影响维度，如供需关系、原材料成

本、市场竞争、季节性需求、促销活动等；是否由数据支撑；是否探讨了因素之间的相互作用（例如，促销如何影响短期供需）；是否发现了某种规律（如特定品牌或规格的价格波动规律）等

③ 购买策略设计（4 分）：设计逻辑是否清晰、合理，能否有效响应价格影响因素的变化；描述是否清晰易懂，步骤明确；参数设定是否合理，是否有明确的依据等

(2) **采购约束满足合规性（10 分）**：旨在考察学生在多约束问题的求解能力

① 采购约束是开展采购事项的基本约束或条件，分 5 个基准赋分，每个占 2 分

- 合格线：至少满足 3 个条件(即 6 分及以上为合格),可参与第(3)项“最优采购 PK 得分”比拼
- 不合格：得分 < 6 分,视为策略无效,第(3)项“最优采购 PK 得分”记 0 分

② 5 个基准赋分要求如下：

检查项目	分值	判定逻辑与扣分标准
预算合规性	2 分	任意时刻“累计花费>20000 元”，此项 0 分。 全程累计采购总花费 ≤20,000 元。 若超支，本项得 0 分。
库存安全性	2 分	任意月份的第一天“核减消耗后库存 < 0”(断货),此项 0 分。 若任意月份断货，本项得 0 分(不允许断货)。 次年 4 月 30 日最终库存必须大于 20 箱,若不满足,本项得 0 分
储备空间阈值	2 分	储备空间最多支持放置 150 箱。任意时刻不可以存储超过 150 箱复印纸。若超过，本项得 0 分。
决策一致性	2 分	购买后的库存计算错误(输入数量+原库存≠输出库存),本项得 0 分
数据一致性	2 分	每一次购买商品的花费不等于现金减少量，本项得 0 分。

(3) **最优采购 PK 得分（10 分）**：旨在考察学生最优决策能力

① 该 PK 阶段，依据学生在满足所有逻辑约束的前提下，全年总购买数量（箱）的排名进行赋分

- 6 分<“采购约束合规性”得分<10 分的同学,不参与排名赋分直接记 2 分
- “采购约束合规性”得分=10 分的同学，参与排名赋分：
  - 分值分布采用线性插值法，最低分为 3 分，拉大分差，增加竞争压力
  - 计分公式为：$score = 3 + round\left(6 \times \frac{N-R}{N-4}\right)$

- N 表示参与排名的总人数；
- R 表示具体名次，第一名 R=1，最后一名 R=N

◆ 赋分比例大致如下：

PK 得分	占比	评价
10 分	3%	顶尖 (冠军组)
9 分	8%	卓越 (前 10%)
8 分	19%	优秀 (前 30%)
7 分	15%	良好 (中上游)
6 分	16%	中等 (及格线以上)
5 分	17%	及格 (中下游)
4 分	17%	低分 (需努力)
3 分	5%	垫底 (后 5%)

附录：最终评测的输入/输出案例

测试组	输入 month.day, price, brand	输出 month.day, price, PurchaseNum, StorageNum, BudgeLeft
test1	6.20,82,齐心 白云海 7.06,94,齐心 白云海 ……	5.1,20 # 运行模型后的第一次输出 6.20,82,30,30,17540 7.06,94,0,10,17540 …… 4.30,xxx # 模型的最后一次输出(余量需保证 5 月使用)
test2	6.21,78.9,誉品 蓝色包装 8.15,82,得力 班达海日常款 ….	5.1,20 # 运行模型后的第一次输出 6.21,78.9,50,50,16055 8.15,82,50,80,11955 …… 4.30,xxx # 模型的最后一次输出(余量需保证 5 月使用)

注意：老师最终问卷调查给出的 10-14 次信息（可采购资讯）可能不是一个月仅一次，采购需要考虑整一年的用量（从本年 5 月 1 日～下一年的 4 月 30 日），以保证最后一次输出能够满足“次年 4 月 30 日最终库存必须大于 20 箱”